
Livro em processo de elaboração.

Título: Gestão de Demanda e Controle de Estoque.

Autora: Tatiana Balbi Fraga.

Profa. do Núcleo de Tecnologia da UFPE.

Este livro está sendo elaborado como parte do projeto de pesquisa proposto por Fraga (2019).

Caso tenha interesse em participar, favor enviar e-mail para: tatiana.balbi@ufpe.br informando como deseja contribuir.

O mesmo endereço de e-mail poderá ser utilizado para críticas e sugestões. Desde já agradeço por qualquer contribuição.

O conteúdo apresentado neste livro estará sendo modificado ao longo de sua elaboração, caso o mesmo seja consultado para elaboração de algum trabalho, favor citar como referência:

Fraga(2023). Gestão de Demanda e Controle de Estoque. Disponível em <https://github.com/tbfraga/book-demand-management-and-inventory-control>. Último acesso em <data do último acesso>.

Chapter 1

Classificação de itens de inventário

No intuito de oferecer um pronto atendimento aos clientes, grande parte das empresas estocam alguns produtos que comercializam. Contudo, o estoque apresenta uma série de preocupações tais como a necessidade de deixar um grande capital parado, o uso de amplo espaço para estocagem e o perecimento dos produtos. Assim torna-se necessária uma correta identificação dos níveis adequados de estoque para os diferentes produtos através de estudos que buscam um ponto de equilíbrio entre as reais necessidades de estocagem e os custos envolvidos. Entre os esforços necessários para a definição de um ponto de equilíbrio podemos citar os estudos de demanda e a busca pela otimização da utilização do espaço disponível para estocagem.

Como muitas organizações comercializam centenas ou até mesmo milhares de itens de inventário, muitas vezes determinar o nível adequado de estoque para cada item se torna excessivamente custoso ou até mesmo impraticável. Portanto uma prática comum consiste em classificar os diversos itens dando a atenção necessária apenas aos itens considerados mais importantes. Entre os métodos de classificação mais conhecidos está o método de análise ABC. Este método será apresentado de forma bem detalhada no capítulo 2.

Uma vez que é dada uma priorização aos itens, é indispensável que seja feita análise de demanda, buscando manter em estoque a quantidade adequada dos principais itens. A análise de demanda deve começar com uma boa previsão. Contudo, há inúmeros métodos para previsão de demanda, sendo que os diferentes métodos produzirão diferentes resultados. Portanto é necessário inicialmente identificar os padrões de demanda dos principais itens, avaliando quais métodos

CHAPTER 1. CLASSIFICAÇÃO DE ITENS DE INVENTÁRIO

serão mais adequados às previsões de cada item. O capítulo 3 aborda sobre algumas metodologias que podem ser aplicadas à identificação e categorização dos diferentes padrões de demanda.

Finalmente, o capítulo 4 aborda sobre importantes metodologias aplicadas à previsão de demanda relacionando tais metodologias aos diferentes padrões observados.

Chapter 2

Método de classificação ABC

O método de classificação ABC foi desenvolvido com base na observação de Pareto, posteriormente generalizada como regra de Pareto ou regra 80-20. De acordo com essa regra, aproximadamente 20% das causas é responsável por 80% dos efeitos.

Pela classificação ABC, os itens de inventário devem ser distribuídos em três grupos - A, B e C - com base em algum critério conhecido. Os itens classificados como A são aqueles mais importantes, os itens B são menos importantes, e os itens C não apresentam importância significativa. Para classificação dos itens é necessário inicialmente lista-los em ordem decrescente, de acordo com sua contribuição para o critério observado. Posteriormente é feita a soma acumulada das contribuições, e a distribuição dos itens entre as três categorias pode ser feita conforme sugerido na Tabela 2.1.

grupo	percentual de itens	contribuição percentual
A	20%	80%
B	30%	15%
C	50%	5%

Table 2.1: Regra sugerida para classificação ABC

Observe que nem sempre será possível encontrar a proporção exata apresentada na Tabela 2.1. Uma forma de contornar essa dificuldade consiste em fixar aproximadamente um dos critérios encontrando o valor para o próximo. Por exemplo, em determinada análise pode ser observado que 10% dos itens são responsáveis por 79,5% dos resultados.

Uma importante questão a ser considerada na aplicação do método ABC é o critério escolhido para a análise. Geralmente é utilizado o critério custo-volume. Contudo outros critérios podem influenciar fortemente na definição da importância de determinado item. Entre tais critérios podemos citar:

- obsolescência: quando um item torna-se rapidamente obsoleto, ou quando este item está próximo de se tornar obsoleto, é necessário atribuir maior atenção ao controle do nível de estoque deste item, portanto itens com maior obsolescência são mais importantes do que itens com menor obsolescência;
- lead-time: itens que podem ser fabricados ou adquiridos rapidamente são menos importantes do que aqueles itens com longos lead-times. O mesmo é válido para itens com lead-times muito variáveis, nesse caso a incerteza faz com que tais itens tornem-se mais importantes;
- substituíbilidade: quando um item pode ser substituído por outro com especificações próximas, isso aumenta a flexibilidade e diminui o tempo de resposta na possibilidade de falta do item, portanto itens mais substituíveis são menos importantes do que itens menos substituíveis;
- reparabilidade: assim como no caso anterior, itens que podem ser rapidamente e facilmente reparáveis aumentam a flexibilidade e o tempo de resposta, portanto itens mais reparáveis são menos importantes do que itens menos reparáveis;
- nível de criticidade: esse aspecto está associado ao custo relacionado à falta de estoque do item. O controle dos níveis de estoque de itens considerados críticos é geralmente muito importante;
- comunalidade: esse aspecto diz respeito às diferentes formas de uso de um item, um item com mais utilidades é mais importante do que um item com menos utilidades.

É preciso observar que muitas vezes é necessário considerar mais do que um único critério, sendo que diferentes critérios podem resultar em diferentes classificações. A literatura apresenta uma série de metodologias que podem ser aplicadas para classificação ABC com múltiplos critérios. A seção 2.1 apresenta um método matricial proposto por Flores & Whybark (1985) para classificação ABC utilizando a comparação de dois critérios. Este método, apesar de ser de fácil aplicação, se torna inadequado quando a classificação envolve três ou mais critérios. A seção 2.2 apresenta uma adaptação do método hierarquia analítica (Saaty, 1987) para classificação ABC envolvendo múltiplos critérios.

2.1 Classificação matricial ABC com dois critérios

Por este método a classificação com dois critérios é feita usando uma matrix de critérios conjuntos. Normalmente essa matriz apresenta forma similar à matriz apresentada na figura 2.1.

		critério 2			legenda
		A	B	C	
critério 1	A				A
	B				B
	C				C

Figure 2.1: Matriz de critérios conjuntos

Neste caso, itens com classificação, de acordo com primeiro e segundo critério, AA, AB ou BA, são classificados como itens do grupo A. Já os itens com classificação CA, BB, e AC são classificados como itens do grupo B. E os itens com classificação CB, BC e CC são classificados como itens do grupo C. Contudo, a forma da matriz poderá ser ajustada conforme os critérios utilizados e a avaliação da chefia. Por exemplo, caso fossem escolhidos como critérios o custo-volume e a criticidade, poderíamos adotar a forma matricial apresentada na figura 2.2.

		criticidade			legenda
		A	B	C	
custo-volume	A				A
	B				B
	C				C

Figure 2.2: Matriz de critérios conjuntos para os critérios custo-volume e criticidade

2.2 Processo de Hierarquia Analítica

O Processo de Hierarquia Analítica (PHA) é um método desenvolvido por Saaty em 1971 que tem como objetivo encontrar uma medida única e padronizada quando considerando vários critérios. Para apresentação de como este método pode ser utilizado para classificação ABC multicritério, estarei usando uma adaptação do exemplo apresentado em uma das publicações do autor (Saaty, 1987). Segue explicação do método:

Considere que em uma empresa, foram feitas quatro classificações para os itens

de inventário, utilizando para cada classificação um dos seguintes critérios: custo-volume, nível de criticidade, obsolescência e lead-time. A Tabela 2.2 apresenta o resultado destas classificações:

custo-volume			criticidade			obsolescência			lead-time		
item	%		item	%		item	%		item	%	
1	50	A	8	60	A	3	20	A	4	30	A
2	30	A	3	20	A	4	20	A	5	20	A
3	8	B	1	4	B	6	20	A	6	20	A
4	4	B	2	4	B	9	20	A	10	10	A
5	3	B	4	4	B	1	5	B	1	8	B
6	1	C	5	4	B	5	5	B	3	7	B
7	1	C	6	1	C	10	5	B	9	2	C
8	1	C	7	1	C	2	3	C	2	1	C
9	1	C	9	1	C	7	1	C	7	1	C
10	1	C	10	1	C	8	1	C	8	1	C

Table 2.2: Classificação ABC para os critérios custo-volume, nível de criticidade, obsolescência e lead-time

O método PHA começa com a criação de uma matriz de comparação entre pares. Para criação dessa matriz, para cada par de critérios é atribuída uma importância relativa, conforme escala apresentada na Tabela 2.3.

intensidade de importância em uma escala absoluta	definição
1	importância igual
3	importância moderada de uma sobre a outra
5	importância forte
7	importância muito forte
9	extrema importância
2, 4, 6, 8	valores intermediários (quando necessário)

Table 2.3: Escala fundamental - fonte: adaptada de Saaty (1987)

A Tabela 2.4 apresenta uma matriz de comparação entre pares que foi criada para o exemplo estudado.

Esta matriz informa a importância de um critério com relação ao outro critério. Por exemplo, o critério criticidade tem importância muito forte quando comparado com o critério custo-volume. Observe que essa matriz é recíproca, ou seja $a_{ij} = a_{ji}$, e que os elementos da diagonal principal terão sempre valor unitário.

Uma vez que a matriz de comparação entre pares é criada, o próximo passo consiste em encontrar os pesos de cada critério. De acordo com o método PHA,

2.2. PROCESSO DE HIERARQUIA ANALÍTICA

critério	custo-volume	criticidade	obsolescência	lead-time
custo-volume	1	1/7	1/5	1/5
criticidade	7	1	2	3
obsolescência	5	1/2	1	1
lead-time	5	1/3	1	1

Table 2.4: Matriz de comparação entre pares

tais pesos são informados pelo autovetor da matriz recém construída.

Para encontrar o autovetor da matriz estudada (A), precisamos inicialmente encontrar o autovalor não nulo da matriz (λ), usando a equação:

$$\det(A - \lambda I) = 0 \quad (2.1)$$

onde I representa a matriz identidade.

Uma vez que encontramos os autovalores, podemos encontrar os autovetores associados usando a equação:

$$(A - \lambda I)v = \emptyset \quad (2.2)$$

onde v é o autovetor associado ao autovalor λ e \emptyset representa um vetor nulo.

Neste caso o autovetor v estará representando os pesos de cada critério estudado.

Exemplo de aplicação:

Para a nossa matriz de comparação entre pares, teremos:

$$\det \left(\begin{vmatrix} 1 & 1/7 & 1/5 & 1/5 \\ 7 & 1 & 2 & 3 \\ 5 & 1/2 & 1 & 1 \\ 5 & 1/3 & 1 & 1 \end{vmatrix} - \lambda \begin{vmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{vmatrix} \right) = 0$$

ou

$$\det \begin{vmatrix} 1-\lambda & 1/7 & 1/5 & 1/5 \\ 7 & 1-\lambda & 2 & 3 \\ 5 & 1/2 & 1-\lambda & 1 \\ 5 & 1/3 & 1 & 1-\lambda \end{vmatrix} = 0$$

$$\begin{aligned} (1-\lambda)\det \begin{vmatrix} 1-\lambda & 2 & 3 \\ 1/2 & 1-\lambda & 1 \\ 1/3 & 1 & 1-\lambda \end{vmatrix} - 7\det \begin{vmatrix} 1/7 & 1/5 & 1/5 \\ 1/2 & 1-\lambda & 1 \\ 1/3 & 1 & 1-\lambda \end{vmatrix} \\ + 5\det \begin{vmatrix} 1/7 & 1/5 & 1/5 \\ 1-\lambda & 2 & 3 \\ 1/3 & 1 & 1-\lambda \end{vmatrix} - 5\det \begin{vmatrix} 1/7 & 1/5 & 1/5 \\ 1-\lambda & 2 & 3 \\ 1/2 & 1-\lambda & 1 \end{vmatrix} = 0 \end{aligned}$$

$$\lambda^4 - 4\lambda^3 + \frac{-19}{21}\lambda = 0$$

ou, multiplicando a equação por $21/\lambda$

$$21\lambda^3 - 84\lambda^2 - 19 = 0$$

Utilizando a calculadora disponível em <https://www.blogcyberini.com/p/calculadora-de-equacoes-do-terceiro-grau.html>, teremos o seguinte autovalor não nulo, r_1 :

$$r_1 = 4.05502341900215$$

e o autovetor:

$$(0.053, 0.491, 0.238, 0.213)$$

Observe que somando os elementos do autovetor, teremos o valor 0,995.

Organizando a matriz com as classificações, temos os resultados encontrados na Tabela 2.5.

Para encontrar a nova classificação multicritério, multiplicamos a essa matriz por v , depois utilizamos o método de classificação ABC.

2.2. PROCESSO DE HIERARQUIA ANALÍTICA

item	custo-volume	criticidade	obsolescência	lead-time
1	50%	4%	5%	8%
2	30%	4%	3%	1%
3	8%	20%	20%	7%
4	4%	4%	20%	30%
5	3%	4%	5%	20%
6	1%	1%	20%	20%
7	1%	1%	1%	1%
8	1%	60%	1%	1%
9	1%	1%	20%	2%
10	1%	1%	5%	10%

Table 2.5: Classificação ABC organizada por item

50%	4%	5%	8%		7,508%
30%	4%	3%	1%		4.481%
8%	20%	20%	7%		16.495%
4%	4%	20%	30%	0.053	13.326%
3%	4%	5%	20%	0.491	7.573%
1%	1%	20%	20%	0.238	9.564%
1%	1%	1%	1%	0.213	0.995%
1%	60%	1%	1%		29.964%
1%	1%	20%	2%		5.730%
1%	1%	5%	10%		3.864%

item	% acumulado
8	29.964 %
3	46.459 %
4	59,785 %
6	69,349 %
5	76,922 %
1	84,430 %
9	90,160 %
2	94,641 %
10	98,505 %
7	99,500 %

Table 2.6: Ordenação de acordo com percentual acumulado

Como a soma dos pesos é 0.995, o percentual acumulado final é também limitado a esse valor. É possível normalizar os valores dos pesos ou dos percentuais acumulados, caso seja necessário. A tabela a seguir foi construída normalizando os percentuais acumulados e então utilizando os seguintes critérios de corte: A

< 70%; B < 90%; e C o restante.

item	% acumulado	classificação
8	30,115 %	A
3	46,692 %	A
4	60,085 %	A
6	69,697 %	A
5	77,309 %	B
1	84,854 %	B
9	90,613 %	C
2	95,117 %	C
10	99,000 %	C
7	100,000 %	C

Table 2.7: Classificação ABC multicritério

2.2.1 Consistência da matriz de comparação entre pares

Ao definir pesos para a matriz de comparação entre pares, é importante observar os seguintes critérios:

critério 1: a matriz deve ser recíproca

Conforme anteriormente informado, na matriz de comparação, a condição $a_{ij} = a_{ji}$ deve ser sempre satisfeita. Adicionalmente os elementos da diagonal principal terão sempre valor unitário.

critério 2: a matriz não pode ser muito inconsistente

Uma matriz quadrada de dimensão n é consistente quando o principal autovalor desta matriz (λ_{max}) tem valor n .

Para que uma matriz seja consistente, é necessário que $a_{ik} = a_{ij} * a_{jk}$. No caso da matriz de pesos apresentada na Tab. 2.4, podemos observar que os pesos não são exatamente consistentes. Por exemplo, se olharmos para o peso da criticidade em relação à obsolescência (a_{23}), teríamos que $a_{23} = a_{21} * a_{13} = 7 * 1/5 = 7/5 = 1.4$, contudo na tabela temos que $a_{23} = 2 > 1.4$. Como a matriz é recíproca, essa inconsistência tende a ser compensada de alguma forma. Na prática, teremos sempre $\lambda_{max} \geq n$.

O CI de uma matriz de comparação é dado por:

$$CI = (\lambda_{max} - n) / (n - 1) \quad (2.3)$$

A taxa de consistência (CR) é obtida comparando o CI com o RI apropriado, de acordo com a matriz abaixo:

n	1	2	3	4	5	6	7	8	9	10
RI	0	0	0.58	0.90	1.12	1.24	1.32	1.41	1.45	1.49

Table 2.8: Index de consistência randômica. Fonte: Adaptação de Saaty (1987).

$$CR = CI/RI \quad (2.4)$$

Para nosso exemplo, temos:

$$CI = (4.055 - 4)/(3) = 0.018$$

$$RI(n = 4) = 0.90$$

$$CR = CI/RI = 0.02$$

De acordo com Saaty (1987), é importante que a taxa de inconsistência da matriz de comparação entre pares seja inferior à 0.10.

Chapter 3

Identificação de padrões de demanda

A previsão de demanda é essencial para o bom planejamento em qualquer empresa. Através de uma boa previsão é possível, entre outras coisas, controlar melhor os níveis de estoque, reduzindo custos e oferecendo um melhor nível de serviço aos clientes.

Conforme mostra Makridakis e Hibon (2000), a literatura apresenta uma grande variedade de metodologias que podem ser utilizadas para previsões de demanda, sendo que a performance dos distintos modelos de previsão varia de acordo a natureza dos dados e um modelo que gera bons resultados para determinada classe de itens de uma empresa pode gerar previsões ruins para outros itens dessa mesma empresa.

Uma estratégia natural utilizada para identificar o modelo de previsão adequado pra cada item consiste em comparar a performance dos distintos modelos candidatos utilizando dados históricos de vendas do item (Ulrich et al., 2022). Contudo, como geralmente as empresas produzem e/ou comercializam uma grande variedade de itens, essa estratégia acaba se tornando um esforço considerável.

De acordo com Ulrich et al. (2022), uma opção viável consiste em agrupar os itens de acordo com seus padrões de demanda, para posteriormente identificar o modelo de previsão adequado pra cada grupo e não mais para cada item individual. Esse capítulo apresenta, de forma bem detalhada, algumas das principais metodologias utilizadas para identificação de padrões de demanda e agrupamento dos itens de acordo com os padrões identificados.

3.1 Padrões de demanda

'Os padrões de demanda são resultados da variação da demanda com o tempo, ou seja, do crescimento ou declínio de taxas de demanda, sazonalidades e flutuações gerais causadas por diversos fatores' (Ballou (2001) apud Werner et al. (2006)).

De acordo com Ballou (2006), quando a demanda apresenta comportamento regular, os padrões de demanda podem ser divididos em componentes de tendência, sazonais ou aleatórios. Já nos casos em que a demanda de determinados itens é intermitente, em função do baixo volume geral e da incerteza quanto a quando e em que nível essa demanda ocorrerá, a série de tempo é chamada de incerta, ou irregular.

Boylan et al. (2008) distribuem os padrões de demanda entre normais, onde a demanda pode ser representada por uma distribuição normal, e não normais, no caso em que isso não é possível. De acordo com os autores, os padrões de demanda não normais podem ser classificados da seguinte forma:

- um item de *demanda intermitente (intermittent)* é um item com ocorrências de demanda pouco frequentes;
- um item de *demanda de movimento lento (slow moving)* é um item cuja demanda média por período é baixa. Isso pode ser devido a ocorrências de demanda pouco frequentes, tamanhos médios de demanda baixos ou ambos;
- um item de *demanda errática (erratic)* é um item cujo tamanho de demanda é altamente variável;
- um item de *demanda esporádica (lumpy)* é um item intermitente para o qual a demanda, quando ocorre, é altamente variável.; e
- um item de *demanda agregada (clumped)* é um item intermitente para o qual a demanda, quando ocorre, é constante (ou quase constante).

Apesar da importância da identificação dos padrões de demanda para identificação dos métodos adequados de previsão, poucos autores tratam deste assunto e poucas técnicas são apresentadas na literatura para essa finalidade.

Businger e Read (1999) aplicam um sistema de agrupamento de itens utilizando um diagrama de plotagem em estrela considerando oito características dos dados de séries temporais: coeficiente de variação, número de zeros, tendência, picos (outliers), sazonalidade, corridas, assimetria e autocorrelação.

Williams (1984) apresenta um esquema para classificação da demanda em suave (smooth), de movimento lento, ou esporádica, particionando a variabilidade da

demanda durante um lead time (C_{LTD}^2) em suas partes causais constituintes: variabilidade dos números de pedidos ($\frac{C_n^2}{L}$), variabilidade dos tamanhos dos pedidos ($\frac{C_x^2}{\bar{n}L}$) e variabilidade dos prazos de entrega (C_L^2).

$$C_{LTD}^2 = \frac{C_n^2}{L} + \frac{C_x^2}{\bar{n}L} + C_L^2 \quad (3.1)$$

onde:

n representa os números de pedidos que chegam em unidades de tempo sucessivas (variáveis randômicas independentes e identicamente distribuídas (IIDRVs), com média \bar{n} e variância $var(n)$),

x representa os tamanhos dos pedidos (IIDRVs, com média \bar{x} e variância $var(x)$),

L representa os prazos de entrega (IIDRVs, com média \bar{L} e variância $var(L)$), e

C_i representa o coeficiente de variação de i .

Tal esquema foi posteriormente revisado por Eaves e Kingsman (2004), considerando também o padrão de demanda irregular. A classificação adaptada por pelos autores é apresentada na tabela a seguir.

$\frac{C_n^2}{L}$	$\frac{C_x^2}{\bar{n}L}$	C_L^2	padrão de demanda
baixo	baixo		suave
baixo	alto		irregular
alto	baixo		de movimento lento
alto	alto	baixo	intermitente
alto	alto	alto	atadamente intermitente

Table 3.1: Classificação dos padrões de demanda de acordo com Eaves e Kingsman (2004)

Observe que os valores dos critérios de corte definidos para diferenciar alto e baixo são arbitrários.

Syntetos et al. (2005) sugerem um esquema de categorização contruído a partir da comparação do erro médio quadrado de três diferentes metodologias (método de Croston, método de Croton modificado e amortecimento exponencial simples). De acordo com esse esquema, os parâmetros quadrado do coeficiente de variação do tamanho da demanda (CV^2) e intervalo médio entre demandas (p) são usados para classificar a demanda entre errática, esporádica, suave e intermitente. A tabela a seguir apresenta a classificação proposta pelos autores.

CV^2	p	padrão de demanda
0.49	1.32	
baixo	baixo	suave
baixo	alto	intermitente
alto	baixo	errática
alto	alto	esporádica

Table 3.2: Classificação dos padrões de demanda de acordo com Syntetos et al. (2005)

Nesse esquema de classificação são definidos os pontos de corte $CV^2 = 0.49$ e $p = 1.32$.

Na seção a seguir o Método de Willians será explicado detalhadamente.

3.2 Método de Williams

Williams (1984) propôs um método para classificação de padrões de demanda entre suave (*smooth*), de movimento lento (*slow moving*) e esporádico (*sporadic*). Neste método, o autor particiona a *variância da demanda durante um lead time* em suas partes causais e usa essas informações para análise do padrão de demanda de séries temporais. Neste livro estaremos chamando este método de Método da Partição da Variância ou, simplesmente, método de Williams. A seguir eu apresento uma definição para a *variância da demanda durante um lead time* e, em seguida, apresento o método de Williams sem, no entanto, estar preocupada com o rigor do desenvolvimento do método. Este desenvolvimento é detalhadamente descrito pelo autor e pode ser consultado no artigo de Williams (1984).

Demanda durante um lead time

Conforme informado anteriormente neste livro, Boylan et al. (2008) define um item de demanda intermitente como sendo um item cujos pedidos ocorrem com pouca frequência. Contudo, na prática o conceito de intermitência é fortemente afetado pelo *lead time* do item. Por exemplo, considere dois itens fabricados em uma mesma fábrica, sendo que o primeiro item tem *lead time* de 1 dia enquanto que o segundo item tem *lead time* de 10 dias. É natural pensar que o item que tem *lead time* de 1 dia tem um processo de fabricação mais simples quando comparado com o segundo item. Portanto é fácil imaginar que o produto com menor *lead time* é mais barato e tem uma maior procura. Nesse caso poderia parecer natural que, considerando o prazo de 10 dias, o número de pedidos do primeiro item fosse 10 vezes maior do que o número de pedidos do segundo item.

Então, buscando criar uma medida que tenha um significado uniforme para os diferentes itens, podemos pensar em intermitência como sendo um parâmetro definido pela razão do *número de pedidos* pelo *lead time*.

No trabalho de Williams (1984), esse parâmetro é chamado *Demanda Durante um Lead Time* (DDLT). Com base neste conceito, o Métodos da Partição da Variância pode ser apresentado, conforme a seguir.

Construção do Método de Partição da Variância

Assumindo que: a) o número de ordens chegando em sucessivas unidades de tempos (*e.g.* semanas) são variáveis randômicas, independentes e identicamente distribuídas (IIDRVs) com média \bar{n} e variância $\text{var}(n)$; b) o tamanho das ordens são IIDRVs com média \bar{x} e variância $\text{var}(x)$; e c) os *lead times* são IIDRVs com média \bar{L} e variância $\text{var}(L)$; a variância do DDLT ($\text{var}(\text{DDLT})$) pode ser particionada em suas três partes constituintes causais. Tal partição pode ser imprecisamente descrita como:

$$\text{var}(\text{DDLT}) = \text{var devido a } n + \text{var devido a } x + \text{var devido a } L \quad (3.2)$$

e representada pela equação:

$$\text{var}(\text{DDLT}) = \text{var}(n)\bar{x}^2\bar{L} + \text{var}(x)\bar{n}\bar{L} + \text{var}(L)\bar{n}^2\bar{x}^2 \quad (3.3)$$

é possível tornar essa equação adimensional:

$$C_{\text{DDLT}}^2 = \frac{C_n^2}{\bar{L}} + \frac{C_x^2}{\bar{n}\bar{L}} + C_L^2 \quad (3.4)$$

onde C_x é o coeficiente de variação do tamanho do pedido, etc.

Sendo a demanda por período (n) uma distribuição de Poisson, com média λ , temos:

$$C_{\text{DDLT}}^2 = \frac{1}{\lambda\bar{L}} + \frac{C_x^2}{\lambda\bar{L}} + C_L^2 \quad (3.5)$$

E, como temos um *lead time* constante, podemos usar a simplificação:

$$C_{\text{DDLT}}^2 = \frac{1}{\lambda\bar{L}} + \frac{C_x^2}{\lambda\bar{L}} \quad (3.6)$$

CHAPTER 3. IDENTIFICAÇÃO DE PADRÕES DE DEMANDA

onde $\frac{1}{\lambda \bar{L}}$ representa o número médio de *lead times* entre as demandas e $\frac{C_x^2}{\lambda \bar{L}}$ é relacionado à esporadicidade da demanda.

Quando estes dois parâmetros são avaliados para os diferentes produtos, observamos que:

- os produtos *não esporádicos* tendem a ter *valores baixos* para estes dois parâmetros;
- os produtos *pouco esporádicos* têm *alto* $\frac{1}{\lambda \bar{L}}$ mas *baixo* $\frac{C_x^2}{\lambda \bar{L}}$;
- os produtos *altamente esporádicos* têm *valores altos* para estes dois parâmetros.

Portanto, podemos usar a seguinte tabela de classificação:

		$\frac{C_x^2}{\lambda L}$ baixo	$\frac{C_x^2}{\lambda L}$ alto
$\frac{1}{\lambda L}$ baixo		A	C
$\frac{1}{\lambda L}$ alto		B	D

Table 3.3: Tabela para classificação de padrões de demanda proposta por Williams (1984)

Onde os produtos A irão apresentar padrão de demanda com pouca esporadicidade, os produtos B terão padrão de demanda de movimento lento, os produtos C terão padrão de demanda frequente, mas com alta variação, e os produtos D terão padrão de demanda com alta esporadicidade (pouca e alta demanda de forma intermitente).

Método de Partição da Variância

Resumindo, o Método de Partição da Variância pode ser explicado da seguinte forma:

Passo 1: para cada produto, usar o histórico de dados para calcular a média da DDLT (λ), a média dos *lead times* (\bar{L}) e o coeficiente de variação entre os pedidos (C_x).

Passo 2: calcular os valores dos parâmetros $\frac{1}{\lambda \bar{L}}$ e $\frac{C_x^2}{\lambda \bar{L}}$.

Passo 3: usar a Tabela 3.3 para classificação dos padrões de demanda dos produtos onde:

- A: produtos com padrão de demanda com pouca esporadicidade;

3.2. MÉTODO DE WILLIAMS

- B: produtos com padrão de demanda de movimento lento;
- C: produtos com padrão de demanda errática;
- D: produtos com padrão de demanda com alta esporadicidade.

Chapter 4

Métodos de previsão de demanda

De acordo com a literatura tradicional, os métodos de previsão de demanda são classificados entre métodos quantitativos e métodos qualitativos. Os métodos qualitativos utilizam o julgamento e o conhecimento tácito como base para o estabelecimento de generalizações e extrapolações que permitirão transformar o conhecimento e intuições em previsões de tendências futuras. Entre as técnicas qualitativas destacam-se o método Delphi e a Análise de Cenários. O método Delphi estrutura o uso do conhecimento e da experiência de um grupo de especialistas para que estes possam utilizar o julgamento intuitivo a fim de chegar ao consenso sobre previsões e tendências específicas. Já na Análise de Cenários são considerados diferentes cenários para as previsões futuras com base em possíveis suposições. Nesse caso a decisão é tomada considerando os resultados e o risco de ocorrência dos diferentes cenários (Wanke e Julianelli, 2006).

Os métodos quantitativos buscam nos dados históricos informações que permitam prever a demanda futura. Estes métodos são divididos entre Métodos Causais e Séries Temporais. Os Métodos Causais buscam explicar as causas que influenciam a demanda. Através destes métodos são identificadas as variáveis que influenciam o comportamento da demanda assim como a correlação entre estas variáveis e, com base nessas identificações, são criadas relações matemáticas que serão utilizadas para as previsões do comportamento futuro da demanda. Entre os Métodos Causais mais conhecidos estão as Regressões Lineares Simples (com uma única variável independente) e as Regressões Lineares Múltiplas (com duas ou mais variáveis independentes). As Séries Temporais estão entre os métodos de previsão de demanda mais aplicados e conhecidos. Estes métodos

tratam da identificação de padrões nos dados históricos (tais como tendência, sazonalidade, ciclo e aleatoriedade) que possam ser reproduzidos para a previsão de comportamentos futuros. Entre as Séries Temporais mais conhecidas estão: as técnicas baseadas em médias (Média Simples, Média Móvel Simples, Média Móvel Dupla); as técnicas de amortecimento exponencial (Amortecimento Exponencial Simples, Método de Brown, Método de Holt, e Método de Winter); e as técnicas de séries temporais em modelo aberto (Análise de Decomposição, Análise Espectral, Análise de Fourier e ARIMA) (Wanke e Julianelli, 2006).

De acordo com Rubio et al. (2011) dentre os métodos de análise de séries temporais baseados em modelos estatísticos, o método ARIMA (Média Móvel Autorregressiva) merece destaque. Os autores esclarecem que este método tem sido amplamente utilizado na literatura já que cobre uma ampla variedade de padrões, variando de séries estacionárias a não estacionárias e sazonais (cíclicas). Os autores também informam que, quando se tratando de dados não lineares, duas das principais técnicas de previsão utilizadas são Indução de Regras e Redes Neurais. As metodologias baseadas em Indução de Regras identificam padrões nos dados estudados expressando estes padrões na forma de regras. São exemplo desta classe de técnicas os Sistemas Inteligentes e os Sistemas Fuzzy. Já as metodologias baseadas em Redes Neurais são entendidas como técnicas de aproximações universais. Isto porque estas técnicas conseguem reproduzir padrões através de simples técnicas de correlação. Como exemplo de técnicas baseadas em Redes Neurais temos as Funções de Base Radial, e os diversos métodos com uma ou com multicamadas de perceptrons.

Apesar dos direcionamentos de Wanke e Julianelli (2006), Rubio et al. (2011) e de vários outros autores, encontrar a metodologia adequada para previsão de demanda pode se tornar uma árdua tarefa. A literatura contemporânea apresenta diversos trabalhos nos quais variadas metodologias são testadas buscando previsões de demanda mais acuradas para casos reais e a variedade de aplicações é surpreendente. Como exemplo, podemos citar o trabalho de Tanizaki et al. (2019) que testam a aplicação de aproximações baseadas em aprendizagem de máquina em análise estatística para previsão de demanda em restaurantes. Os autores analisam a utilização dos métodos Regressão Linear Bayesiana, Regressão por Árvore de Decisão Impulsionada e Regressão por Floresta de Decisão para aprendizado de máquina, e do método stepwise para a análise estatística. Merkurjeva et al. (2019) compara os métodos de Média Móvel Simples, Regressão Múltipla e Regressão Simbólica com Algoritmos Genéticos para previsão de demanda na cadeia de suprimentos farmacêutica, demonstrando a superioridade do último método. Já Maqsood et al. (2019) testam algoritmos baseados em Regressão Linear, Regressão de Vetores de Suporte e Aprendizado Profundo para a previsão da bolsa de valores. É importante ressaltar que, conforme citado por Andrawis et al. (2011), é um fato conhecido que a combinação de vários métodos de previsão tende a gerar resultados dramaticamente melhores. De acordo com Atiya (2019), a motivação por trás da combinação dos métodos de previsão é o fato de que os problemas de previsão geralmente possuem poucos ou limitados

dados históricos. Assim, para o autor, do ponto de vista prático, não é possível obter a especificação correta do processo de geração de dados subjacentes. Se torna benéfico portanto proteger contra a imprecisão resultante do modelo de previsão derivado, considerando vários modelos de previsão e combinando suas previsões. Contudo, vale ainda ressaltar que, conforme observado por Andrawis et al. (2011), o método de previsão combinado herda as performances de seus métodos constituintes e, portanto, é essencial que as diferentes metodologias sejam testadas e que sejam escolhidas aquelas que apresentam os melhores resultados.

Bibliography

- Andrawis, R. R., Atiya, A. F., e El-Shishiny, H. (2011). Forecast combinations of computational intelligence and linear models for the nn5 time series forecasting competition. *International Journal of Forecasting*, Vol. 27, pp. 672–688.
- Atiya, A. F. (2019). Why does forecast combination work so well ? *International Journal of Forecasting*, in press, corrected proof, Available online 24 May 2019.
- Ballou, R.H. (2001). *Gerenciamento da Cadeia de Suprimentos: Planejamento, Organização e Logística Empresarial*, 4. ed., Porto Alegre: Bookman.
- Ballou, R.H. (2006). *Gerenciamento da Cadeia de Suprimentos / Logística Empresarial*, 5. ed., Porto Alegre: Bookman.
- Boylan, J.E., Syntetos, A.A., e Karakostas, G.C. (2008). 'Classification for forecasting and stock control: a case study'. *Journal of the Operational Research Society*, Vol. 59, pp. 473–481.
- Businger, M.P., e Read, R.R. (1999). 'Identification of demand patterns for selective processing: a case study'. *Omega, Int. J. Mgmt Sci.*, Vol. 27, pp. 189–200.
- Eaves A.H.C., e Kingsman B.G. (2004). 'Forecasting for the ordering and stock-holding of spare parts'. *J. O. Opl. Res. Soc.*, Vol. 55, pp. 431–437.
- Flores, B.E., and Whybark, D.C. (1986). 'Multiple Criteria ABC Analysis'. *International Journal of Operations & Production Management*, Vol. 6, No. 3, pp. 38–46.
- Fraga, T.B. (2019). 'Estudo de Métodos de Previsão de Demanda e Proposição de Metodologia Combinada no Contexto das Micro e Pequenas Empresas do Agreste Pernambucano'. Projeto de Pesquisa registrado em 09/11/2019, e aprovado pela Pró-reitoria de Pesquisa da UFPE em 11/02/2021 (Processo SIPAC 23076.057489/2019-21).

BIBLIOGRAPHY

- Makridakis, S.G., Wheelwright, S.C., Hyndman, R.J. (1998). *Forecasting: Methods and Applications*, 3. ed., Wiley.
- Makridakis, S. e Hibon, M. (2000). 'The M3-Competition: results, conclusions and implications'. *International Journal of Forecasting*, Vol. 16, pp. 451–476.
- Maqsood, H., Mehmood, I., Maqsood, M., Yasir, M., e Muhammad, K. (2019). A local and global event sentiment based efficient stock exchange forecasting using deep learning. *International Journal of Information Management*, in press, corrected proof.
- Merkuryeva, G., Valberga, A. , e Smirnov, A. (2019). Demand forecasting in pharmaceutical supply chains: A case study. *Procedia Computer Science*, Vol. 149, pp. 3–10.
- Rubio, G., Pomares, H., Rojas, I., e Herrera, L. J. (2011). A heuristic method for parameter selection in ls-svm: Application to time series prediction. *International Journal of Forecasting*, Vol. 27, pp. 725–739.
- Saaty, R.W. (1987). 'The Analytic Hierarchy Process - what it is and how it is used'. *Mathl Modelling*, Vol. 9, No. 3-5, pp. 161–176.
- Syntetos, A.A., Boylan, J.E., e Croston, J.D. (2005). 'On the categorization of demand patterns'. *Journal of the Operational Research Society*, Vol. 56 (5), pp. 495–503.
- Tanizaki, T., Hoshino, T., Shimmura, T., Takenaka, T. (2019). Demand forecasting in restaurants using machine learning and statistical analysis. *Procedia CIRP*, Vol. 79, pp. 679–683.
- Ulrich, M., Jahnke, H., Langrock, R., Pesch, R., e Senge, R. (2022). 'Classification-based model selection in retail demand forecasting'. *International Journal of Forecasting*, Vol. 38 (1), pp. 209–223.
- Wanke, P., e Julianelli, L. (2006). *Previsão de vendas: processos organizacionais & métodos quantitativos e qualitativos*. Editora Atlas.
- Werner, L, Lemos, F.O., Daudt, T. (2006). 'Previsão de demanda e níveis de estoque uma abordagem conjunta aplicada no setor siderúrgico'. XIII SIMPEP, Bauru, SP, Brasil.
- Williams, T.M. (1984). 'Stock control with sporadic and slow-moving demand'. *Journal of the Operational Research Society*, Vol. 35 (10), pp. 939–948.